

Introducción al Aprendizaje Profundo

Bere & Ricardo Montalvo Lezama

github.com/richardtml/riiaa-20-aa



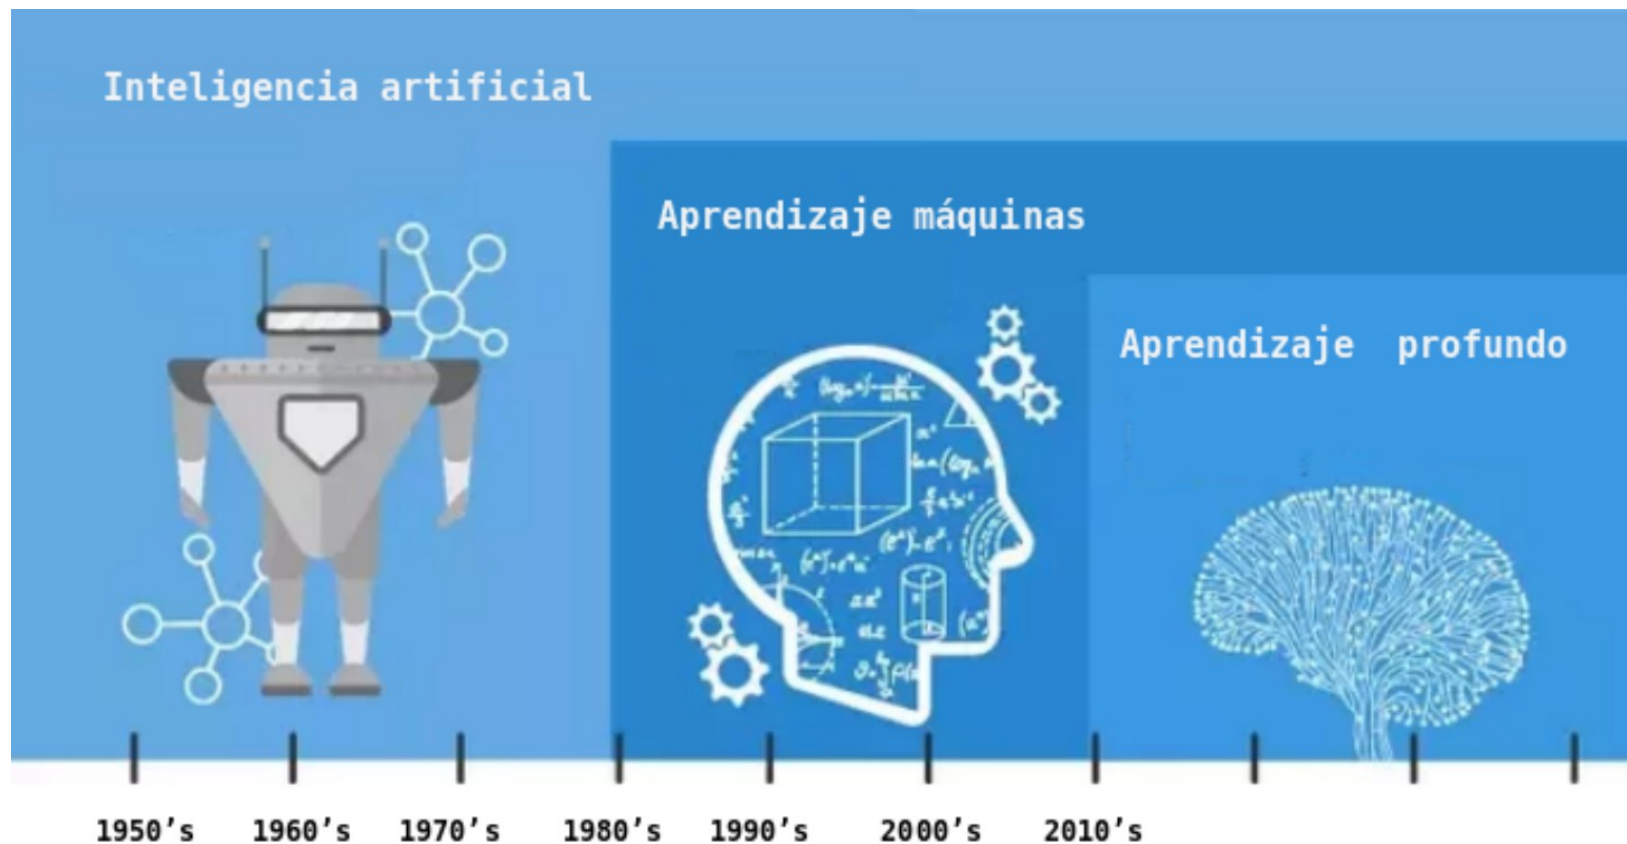
Agosto 2020

En este taller

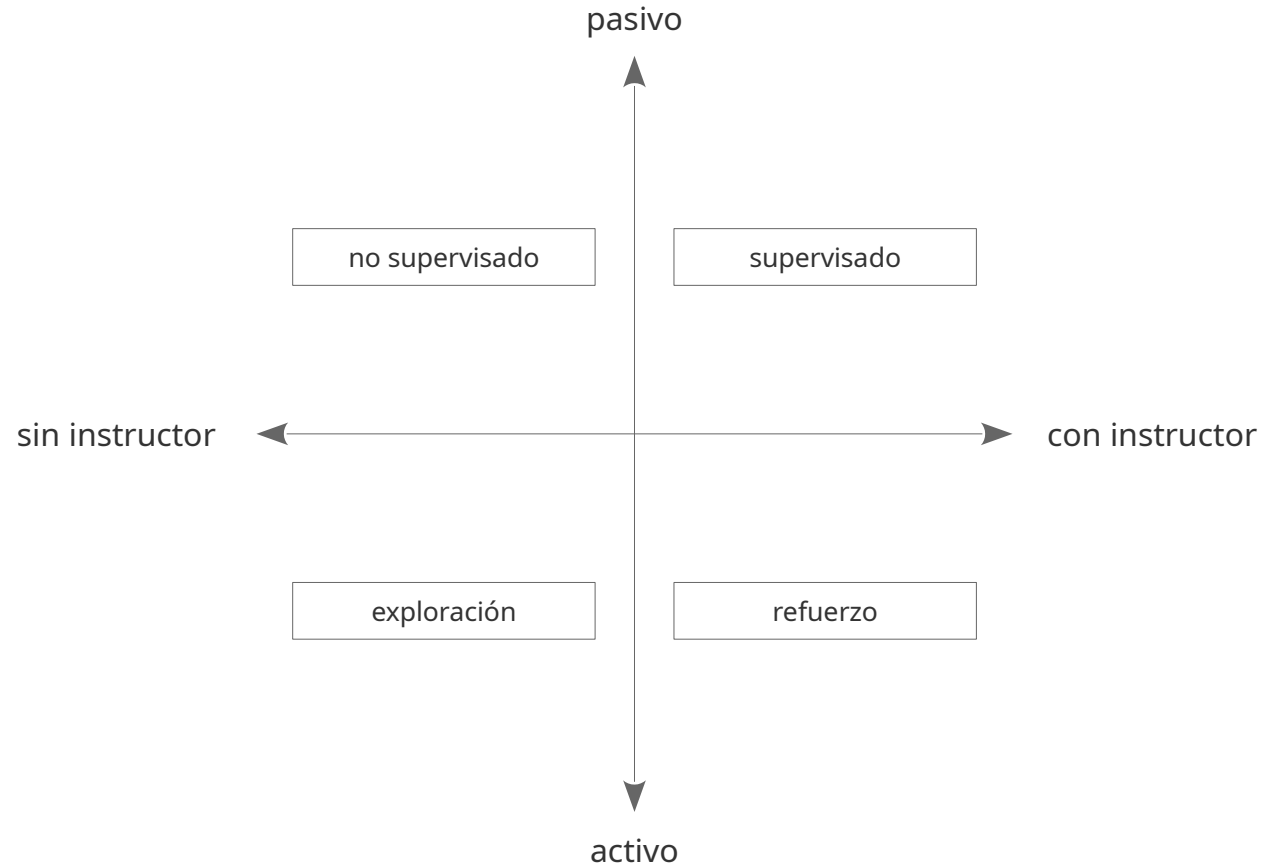
- Aprendizaje de Máquinas
 - Introducción
 - Regresión lineal
- Aprendizaje Profundo
 - Perceptrón multicapa
 - Redes convolucionales
 - Panorama

Aprendizaje de Máquinas

IA, AM y AP



Tipos de aprendizaje




¿Cómo funciona el aprendizaje de máquinas?

- Programas que aprenden a partir de ejemplos.
- Se aprende un modelo: función parametrizada.



Aprendizaje supervisado



- La función de pérdida compara la salida verdadera con la salida predicha.
- Se minimiza la pérdida para actualizar los parámetros del modelo.
- El más común de los tipos de aprendizaje.



Regresión y Clasificación



Regresión

¿Cual será la temperatura mañana?




Clasificación

¿Cómo será el día mañana?




Regresión lineal

- Regresión: predecir una salida continua.



modelo



función de
pérdida

repetir hasta converger:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

repetir hasta converger:


$$\theta_0 := \theta_0 - \frac{\alpha}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})$$

$$\theta_1 := \theta_1 - \frac{\alpha}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x^{(i)}$$

algoritmo de
entrenamiento

Descenso por gradiente

- Avanzar hacia la dirección con menor pérdida.

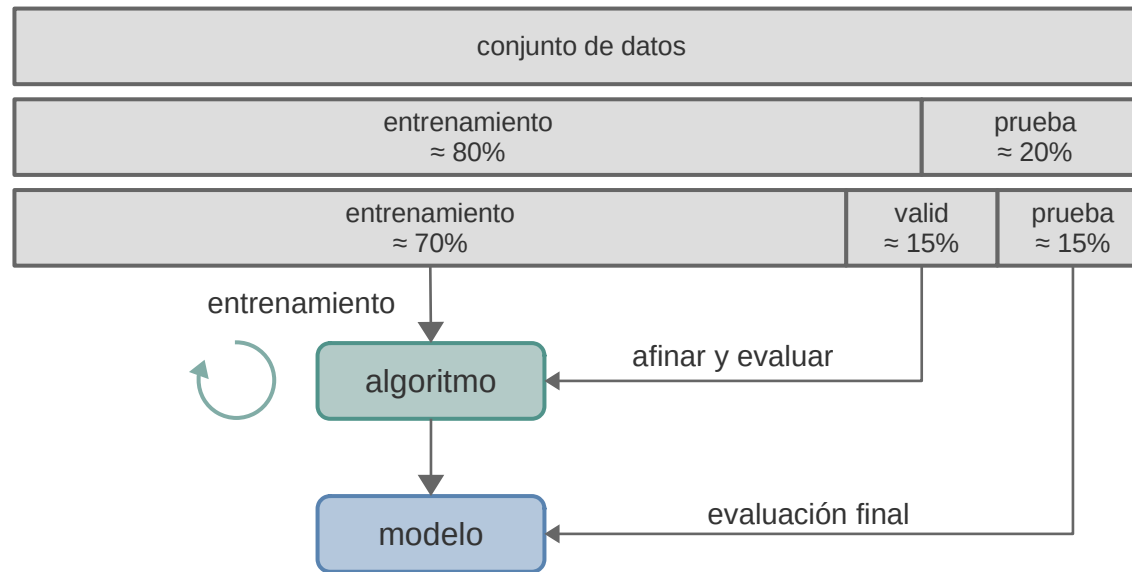


repetir hasta converger:


$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

Evaluación

- Aprendizaje iterativo en entrenamiento y validación.
- Evaluación final en prueba.



Limitaciones



Aprendizaje Profundo

Una receta con mucho éxito


IMAGENET

14M de imágenes
21K categorías

YouTube-8M

8M de videos
4.8K categorías

+




+



PyTorch

=

TensorFlow



datos masivos
etiquetados

arquitecturas
sofisticadas

infraestructura



estado
del arte

Representación de imágenes

- Se representan con una matriz de valores de píxeles por cada color.



3x224x224


 $3 \times 5 \times 5$ 

canales RGB


- MNIST 1x28x28, CIFAR-10 3x32x32, ImageNet 3x256x256.

Perceptrón multicapa


- Conjuntos de neuronas completamente conectadas.



red de 1 capa



red de 2 capas




neurona

Funciones de activación (I)

- Función no lineal a la salida de la neurona.
 - Sigmoide: clasificación binaria.
 - Softmax: clasificación multiclase.


Sigmoide

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-x)}$$



Softmax


$$z = \text{softmax}(x)$$
$$z_j = \frac{\exp(x_j)}{\sum_k \exp(x_k)}$$





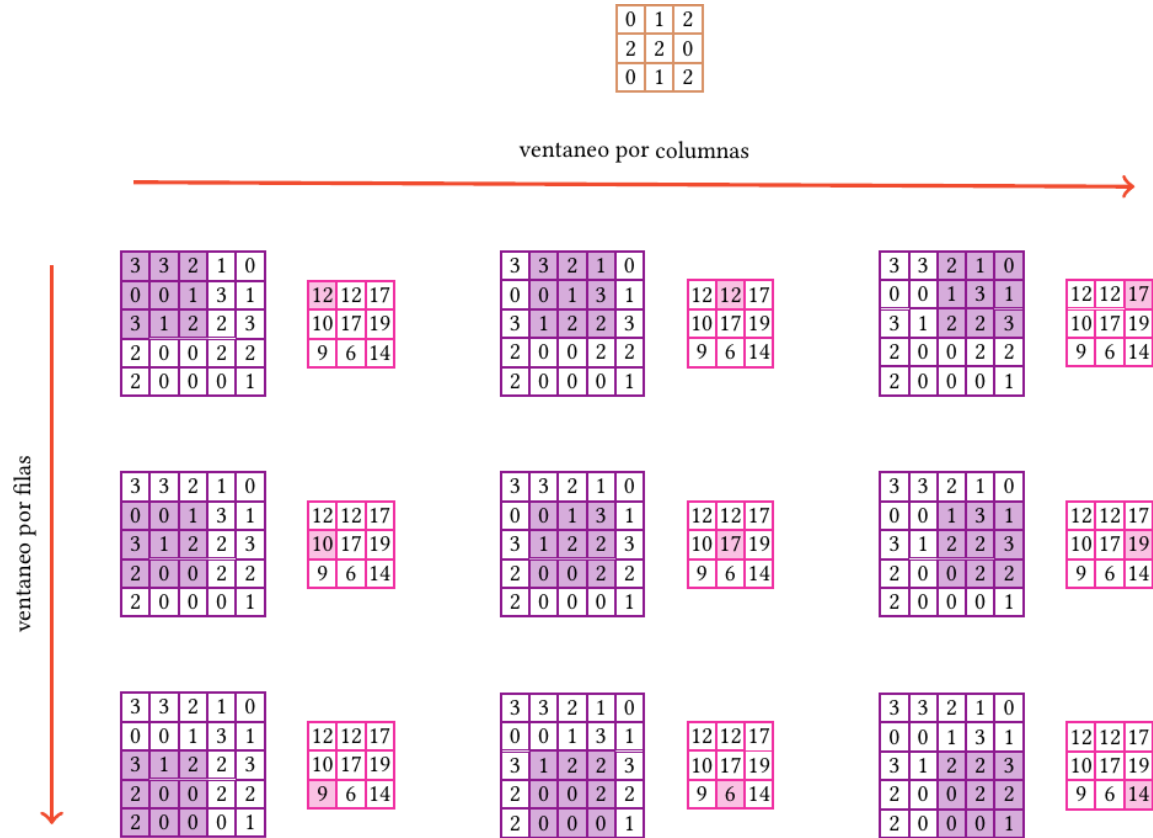
¡tiempo de programar!
1a_mlp.ipynb

Redes Convolucionales




Arquitectura LeNet

Convolución



Convolución: entrada 5×5 , salida 3×3 , filtro 3×3 .

Muestreo




Muestreo máximo: entrada 5×5 , salida 3×3 , paso 1×1 .

Funciones de activación (II)

- Función no lineal a la salida de la neurona.
 - ReLu: capas ocultas.

ReLu

$$\text{relu}(x) = \max(0, x)$$




Funciones de activación (II)

- Función no lineal a la salida de la neurona.
 - ReLu: capas ocultas.
 - Softmax: clasificación multiclase.

ReLu


$$\text{relu}(x) = \max(0, x)$$



Softmax

$$z = \text{softmax}(x)$$

$$z_j = \frac{\exp(x_j)}{\sum_k \exp(x_k)}$$





¡tiempo de programar!
2a_cnn.ipynb

Tareas de Visión

clasificación




gato

clasificación
+ localización



gato

detección



gato, pato, pato

segmentación




gato, pato, pato

un objeto


múltiples objetos

Arquitecturas


Inception



ResNet



DenseNet





¡Gracias!

Ricardo Montalvo Lezama

<http://turing.iimas.unam.mx/~ricardoml/>
ricardoml@turing.iimas.unam.mx

Bere Montalvo Lezama

<http://turing.iimas.unam.mx/~bereml/>
bereml@turing.iimas.unam.mx